

基于 SeleCom 软压缩框架的

Stage 3 联合对齐微调设计与实现指南

长文本软压缩课题组

2026 年 5 月 26 日

摘要

在检索增强生成 (RAG) 长文本软压缩领域, SeleCom 架构通过「查询约束选择」范式成功打破了传统「全量压缩」的局限性。然而, 分阶段解耦训练 (Modular Decoupling) 仍存在选择器 (Selector) 与生成器 (Generator) 联合优化不一致 (Disjoint Optimization Mismatch) 的问题。本文旨在为引入 **Stage 3: 联合对齐训练 (Joint Alignment Training)** 提供系统性的理论支撑与工程实现指南。本方案详细设计了多任务联合约束损失函数, 梳理了高质量训练数据构建策略, 并给出了学术实施的工程避坑建议。

1 核心动机验证实验: 语义漂移的可量化性

1.1 实验假设

Stage 1 训练所得的 Selector 是为彼时冻结版本的 Generator 量身定制的。Stage 2 对 Generator 进行指令微调后, Generator 的内部表示发生漂移, Selector 生成的压缩嵌入 $\mathbf{E}$ 与 Generator 实际期望之间产生 **隐性语义错位 (Latent Semantic Misalignment)**。

我们将这一现象定义为**训练后漂移 (Post-training Drift)**, 并通过以下轻量级实验对其进行量化验证。

1.2 实验设计

对同一批样本 $\{(q_i, d_i)\}_{i=1}^N$, 固定 Stage 1 训练完毕的 Selector ϕ 和 Projector W_p , 生成压缩嵌入:

$$\mathbf{E}_i = W_p(\text{Selector}_\phi(q_i, d_i)) \quad (1)$$

随后分别将 $\mathbf{E}_i$ 输入两个不同状态的 Generator, 获取其对答案首 token 的输出 logits 分布:

- $P^{(1)}(\cdot | q_i, \mathbf{E}_i)$: Stage 1 结束时冻结的 Generator θ_1 的输出分布;
- $P^{(2)}(\cdot | q_i, \mathbf{E}_i)$: Stage 2 微调后的 Generator θ_2 的输出分布。

1.3 量化指标

以 KL 散度衡量两个 Generator 对同一压缩嵌入的解码分布差异：

$$\mathcal{D}_{\text{drift}} = \frac{1}{N} \sum_{i=1}^N D_{\text{KL}} \left(P^{(1)}(\cdot | q_i, \mathbf{E}_i) \parallel P^{(2)}(\cdot | q_i, \mathbf{E}_i) \right) \quad (2)$$

若 $\mathcal{D}_{\text{drift}}$ 显著大于零（经验阈值 > 0.5 ），则表明 Stage 2 微调已使 Generator 对压缩嵌入的解码期望发生实质性偏移，Stage 3 联合对齐训练的动机得到实验数据的直接支撑。

1.4 实验成本分析

该实验**无需任何训练过程**，仅需对两个已保存的 checkpoint θ_1 、 θ_2 各执行一次前向推理，具体流程如下：

1. 保存 Stage 1 结束时的 Generator checkpoint θ_1 ；
2. 保存 Stage 2 结束时的 Generator checkpoint θ_2 ；
3. 从验证集中采样 $N = 500$ 条 (q_i, d_i) 样本；
4. 以固定的 ϕ 、 W_p 生成压缩嵌入 $\mathbf{E}_i$ ；
5. 分别用 θ_1 、 θ_2 前向推理，记录 logits；
6. 按公式 (2) 计算 $\mathcal{D}_{\text{drift}}$ 。

完整流程在单张 GPU 上预计耗时不超过 30 分钟，可作为正式 Stage 3 实验启动前的**低成本动机验证**优先执行。

2 核心技术优势：完全可微的软压缩梯度流

在标准的「检索-生成」联合训练中（如 CLaRa 的端到端检索阶段），由于从海量文档中进行 Top- k 离散文档选择是**不可微 (Non-differentiable)** 的，因而往往必须引入直通估计器 (Straight-Through Estimator, STE) 或强化学习 (RL) 算法来强行传递梯度。

然而，在 Stage 3 阶段，输入文档 D 已经由检索器选定，训练重心在于**文档级上下文压缩 (Context Compression)**。在此场景下，信息从输入文档到选择器生成 (ENCODE) 标记，再经投影器 (MLP) 将其转换为虚拟嵌入，最终输入生成器，整个前向传播流是**完全连续且可微 (Fully Continuous and Differentiable)** 的。

因此，无须任何复杂的随机梯度估计器，直接通过标准的反向传播 (Backpropagation) 机制，即可将生成器的输出误差直接转化为对选择器参数的精细微调信号，实现真正的「共脑」协同推理。

3 Stage 3 训练损失函数设计

在 Stage 3 中，选择器 ϕ 、投影器 W_p 和生成器 θ 均处于解锁（或通过 LoRA 局部解锁）状态。联合优化的目标是既要提升下游 QA 的表现，又要防止软压缩方法中常见的「表示坍塌」与「注意力塌陷」问题。为此，我们设计了多任务联合约束损失函数：

$$L_{\text{joint}} = L_{\text{task}} + \alpha L_{\text{align}} + \beta L_{\text{reg}} \quad (3)$$

其中， α 和 β 为调节平衡的超参数。

3.1 下游任务损失 (Task Loss): L_{task}

这是联合优化的核心，通过生成器预测真实答案的自回归交叉熵损失 (Next Token Prediction, NTP) 来实现：

$$L_{\text{task}} = - \sum_{t=1}^{|A|} \log P_{\theta}(a_t | Q, E, a_{<t}) \quad (4)$$

其中 $E = \text{Proj}(\text{Selector}_{\phi}(Q, D))$ 为投影器转换后的压缩嵌入。通过这种前向传导，下游生成误差的梯度将天然地回传至选择器：

$$\frac{\partial L_{\text{task}}}{\partial \phi} = \frac{\partial L_{\text{task}}}{\partial E} \cdot \frac{\partial E}{\partial H} \cdot \frac{\partial H}{\partial \phi} \quad (5)$$

这迫使选择器主动调整信息提取策略，以最有利于生成器回答问题的方式对长文本进行「有损但高密度」的自适应编码。

3.2 对齐损失 (Alignment Loss): L_{align}

为了防止端到端训练时，选择器和投影器由于极力迎合生成器的任务损失，进而生成与原始语义严重偏离的「对抗性高维向量」，我们引入辅助性对齐损失。针对 RAG 软压缩场景，我们提供以下三种可选对齐范式：

- **方案 A：输出概率级 KL 散度 (Logit-level Distillation)** 让输入完整原始文本 D 的强大教师生成器产生目标标记的概率分布 P_{teacher} ，并在模型顶层（词表空间）要求学生模型逼近，以约束输出语义的忠实度：

$$L_{\text{align}} = D_{\text{KL}}\left(P_{\text{teacher}}(a_t | Q, D, a_{<t}) \parallel P_{\text{student}}(a_t | Q, E, a_{<t})\right) \quad (6)$$

- **方案 A'：基于 Oracle 通道重构的 Attention 级对齐 (Attention-level Distillation, 是单独训练选择器的)**

为彻底打破分阶段微调导致的选择器与生成器之间的「单向信息瓶颈」，我们利用未压缩的「教师生成器 (Oracle 通道)」在阅读完整上下文时的内部自注意力权重，作为软监督信号来指导选择器。

对于给定样本 $(Q, D, A_{\text{target}})$ ，对齐过程分为三步：

1. **Oracle 生成器通道 (Teacher Pass)**: 将未压缩的原始文本 D 与查询 Q 送入生成器 θ 。提取其最后一层自注意力矩阵。将所有答案标记 (Answer Tokens) 对文档 D 的注意力权重进行多头平均和 Pooling 聚合, 得到生成器对原始文档的真实「需求分布」 $\mathbf{A}_{\text{gen} \rightarrow \text{doc}}$:

$$\mathbf{A}_{\text{gen} \rightarrow \text{doc}} = \text{Softmax} \left(\frac{\mathbf{a}_{\text{gen} \rightarrow \text{doc}}}{T_g} \right) \in \mathbb{R}^{|D|} \quad (7)$$

其中 T_g 为调和分布平滑度的温度系数。

2. **学生选择器通道 (Student Pass)**: 运行选择器 ϕ , 提取 p 个 (ENCODE) 标记在编码过程中对原始文档 D 的最后一层自注意力权重, 同样进行平均和归一化, 得到选择器的「提取分布」 $\mathbf{A}_{\text{sel} \rightarrow \text{doc}}$:

$$\mathbf{A}_{\text{sel} \rightarrow \text{doc}} = \text{Softmax} \left(\frac{\mathbf{a}_{\text{sel} \rightarrow \text{doc}}}{T_s} \right) \in \mathbb{R}^{|D|} \quad (8)$$

其中 T_s 为学生端温度系数。

3. **注意力对齐损失计算**: 由于两个分布的支持集完全一致 (均为原始文档长度 $|D|$), 利用 KL 散度约束选择器去逼近生成器的阅读偏好:

$$L_{\text{align}} = D_{\text{KL}}(\mathbf{A}_{\text{gen} \rightarrow \text{doc}} \parallel \mathbf{A}_{\text{sel} \rightarrow \text{doc}}) = \sum_{i=1}^{|D|} \mathbf{A}_{\text{gen} \rightarrow \text{doc}}(i) \log \left(\frac{\mathbf{A}_{\text{gen} \rightarrow \text{doc}}(i)}{\mathbf{A}_{\text{sel} \rightarrow \text{doc}}(i)} \right) \quad (9)$$

这种对齐教导选择器「如何像生成器一样做高价值信息过滤」, 直接在特征提取层面消除了表示偏置。

- **方案 B: 表征级 MSE 对齐损失** 强制要求投影后的压缩嵌入的平均表征在几何距离上靠近原始未压缩文本在生成器中的平均表征:

$$L_{\text{align}} = \text{MSE}(\text{Mean}(E), \text{Mean}(\text{Emb}_{\text{gen}}(D))) \quad (10)$$

3.3 范数正则化损失 (Norm Regularization Loss): L_{reg}

根据香农定理及软压缩退化分析, 在端到端压力下, 模型倾向于通过无节制膨胀压缩嵌入的范数 R_Z 来获取最大化的通道容量, 这会导致生成器发生注意力坍塌、丧失指令遵循能力。为约束压缩嵌入的 L_2 范数, 使其与生成器原生标记嵌入的平均范数 μ_{norm} 保持一致, 设计正则化惩罚项:

$$L_{\text{reg}} = \sum_{i=1}^n \max \left(0, \|e_i\|_2^2 - \mu_{\text{norm}}^2 \right) \quad (11)$$

3.4 方案三: 迭代训练替代单向蒸馏

不增加 Stage3, 而是把 Stage1 和 Stage2 做成循环: Stage1 $\rightarrow$ Stage2 $\rightarrow$ Stage1' (用 Stage2 的 generator 重新训练 selector) $\rightarrow$ Stage2' $\rightarrow$... 每轮 Stage1 都用更新后的 generator 作为目标模型, selector 逐渐适应 generator 的实际偏好。实现简单, 不需要设计新的损失函数, 直接复用现有训练流程。

4 训练数据来源与构建策略

Stage 3 的对齐微调聚焦于精细语义映射，因此不需要 Stage 1 大规模的粗粒度数据。我们建议采用以下三类高质量数据集组合构建 Stage 3 的训练数据 mix：

4.1 直接复用 SeleCom 开源的难度分级数据集

SeleCom 团队在 Hugging Face 开源了经过“LLM-as-a-judge”过滤的 1400 万三元组数据集（地址：https://huggingface.co/datasets/Ryan7458/SeleCom_Training）。

- **筛选策略：**在 Stage 3 训练中，应主动过滤掉难度标签为 1（事实过于简单）的样本，只抽取高难度等级（Difficulty Level 3 & 4）的子集。只有在需要复杂推理、信息高度重组的场景下，联合微调所激发的选择器-生成器协同效应才最为显著。

4.2 构建“双向提炼”蒸馏数据集（PISCO/OSCAR 范式）

利用标准的 RAG 任务（如 Natural Questions, HotpotQA）进行教师模型行为蒸馏。

1. 将 $(Q, D_{1:5})$ 输入未压缩的强大的 Teacher RAG 模型，获取高质量生成回答 A_{teacher} ；
2. 保存教师模型在生成每一个 token 时的 **logits 概率分布**；
3. 将 $(Q, D_{1:5}, A_{\text{teacher}}, \text{logits})$ 作为三元组注入 Stage 3 训练集。

4.3 引入多跳与对抗性噪声数据集

为强化选择器在生成器监督下的噪音过滤与信息关联能力：

- **多跳问答数据集**（如 HotpotQA, 2WikiMultihopQA）：强制选择器学习在多篇文档中寻找互补性证据；
- **人为混合噪声数据**：在检索出的黄金文档中，随机混入不相关的干扰文档，迫使选择器学会在面对生成器目标反馈时，主动将噪声文档压缩成「零信息」的无意义状态。

5 避坑指南与工程实现建议

1. 采用多 LoRA 适配器（Multi-LoRA）架构：

全量微调 0.6B 选择器与 7B 生成器会导致灾难性遗忘与显存爆炸。应在 Qwen3-0.6B 选择器上挂载适配器 LoRA_{ϕ} ，在 Mistral/Qwen2.5 生成器上挂载另一适配器 LoRA_{θ} ，并在 Stage 3 中仅更新这两个 LoRA 与 Projector MLP 的参数。

2. MLP 投影器的初始化与学习率：

由于投影器跨越了异构模型的表示空间，其在 Stage 3 开始时，必须使用 **Stage 1 训练好的权重进行初始化**。在联合训练中，可将其学习率设置为略高于 LoRA 适配器的 1.5 倍，确保映射空间快速对齐。

3. 显存优化与并行技巧:

当梯度回传跨越生成器与选择器时，中间状态会消耗极大的显存。请务必在 Generator 中开启 **Gradient Checkpointing**，并基于 DeepSpeed ZeRO-3 或 FSDP 进行分布式多卡并行，以保障学术服务器在有限的显存资源下不发生 OOM 崩溃。